Atividades

1. Instalar e importar as bibliotecas do spark e pyspark (as mesmas disponibilizadas nas aulas).
2. Criar um spark context com o app name = “AC5 DataEng”.
3. Subir o arquivo “vendas.parquet” para o ambiente do Colab.
4. Criar um dataframe lendo o arquivo vendas.parquet.

   df = spark.read.format(“parquet”).load(caminho)
5. Converter a coluna data para o tipo DateType.
6. Criar as colunas, utilizando as funções spark.sql.functions.year, spark.sql.functions.month , spark.sql.functions.dayofMonth:
   a. ano = ano da coluna “data”. (spark.sql.functions.year)
   b. mes= mes da coluna “data”. (spark.sql.functions.month)
   c. dia= dia da coluna “data”. (spark.sql.functions.dayofMonth)
7. Na coluna sms, se caso o valor for null , troque por False (use a função spark.sql.functions.when (df.sms.isNull(),False).otherwise(df.sms))
8. Crie uma coluna chamada “total” que deve ser a multiplicação das colunas “vlr” e “qtd”.
9. Grave o dataframe particionado por ano, mes e dia no formato “parquet” de nome “vendas_tratadas”.
10. Crie uma tabela temporaria chamada “vendas_table” (df.registerTempTable(“vendas_table”)).
11. Crie um dataframe spark.sql utilizando a query spark.sql(“select distinct cidade from vendas_table”). Grave esse dataframe no formato “parquet” de nome “cidade”.
12. Crie um novo dataframe chamado “produto” selecionando as colunas: “des_produto”,”des_familia”, “des_secao”, “des_categoria”,”des_sub_categoria”. Remova possíveis espaços no começo e no final das colunas (spark.sql.functions.trim). Deixe apenas valores únicos (df.distinct()). Grave esse dataframe como parquet “produto”.
13. Crie um dataframe chamado “venda_mulheres”, selecionando todas as colunas e filtrando apenas vendas realizadas pelo sexo “F”, grave esse dataframe no formato json “venda_mulher”. (df.write.format(“json”).save(“venda_mulher”)).
14. Crie um dataframe chamado “venda_unicas”, selecionando todas as colunas e filtrando apenas vendas com a qtd igual 1 e o vlr menor que 10. Grave esse dataframe no formato csv “venda_unica”. (df.write.format(“csv”).save(“venda_unica”)).